VALIDACIÓN Y PRUEBAS

Modelo de fallas futuras a 72 h

Fase II - Semana 8. Documento reproducible con cifras de la ejecución verificada por GitHub Actions. Las fallas, sensores y máquinas son simulados.

1. Resultados principales

Se generaron **129,600** observaciones de 60 máquinas cada seis horas y **318** eventos de falla sintéticos. La etiqueta mira exclusivamente las siguientes doce mediciones (72 horas).

Conjunto	n	ROC-AUC	AP	Prec.	Recall	F1
Validación	14797	0.824	0.206	0.209	0.368	0.266
Prueba temporal	19906	0.807	0.229	0.208	0.372	0.267
Piloto 12 máquinas no vistas	4991	0.862	0.242	0.164	0.375	0.228

Umbral elegido en validación: **0.64**, maximizando F2 con precisión mínima del 20% cuando es factible. No se recalibró con test temporal ni con máquinas piloto.

2. Anticipación antes del evento

Conjunto	Fallas detectadas	Recall de eventos	Anticipación media
Prueba temporal	30 / 54	55.6%	61.6 h
Piloto no visto	8 / 11	72.7%	59.2 h

Estas métricas corresponden a eventos de falla sintéticos elegibles con al menos 72 horas de historia previa en el periodo de prueba. El reducido número de eventos piloto exige cautela al interpretar su recall.

3. Construcción causal de la etiqueta y contención de fuga

Para una lectura t de una máquina, failure_next_72h=1 solo si existe un evento en (t,t+72h]. Se excluyen el propio instante de falla y los períodos de máquina detenida. Los últimos doce registros se censuran porque su futuro es desconocido. Los indicadores de temperatura/vibración y desgaste usan únicamente lecturas hasta t.

Conjunto	Registros	Positivos
train	66,136	1847
validation	14,797	511
test_temporal	19,906	648
test_unseen_machines	4,991	144

Se usaron 48 máquinas para entrenar y validar en períodos cronológicos; existe una purga de 12 lecturas al cambiar de partición. Las 12 máquinas PM-049 a PM-060 quedaron completamente excluidas del ajuste y sirven como evaluación separada de generalización a equipos simulados no vistos.

4. Interpretación de costos operativos

En test temporal se observaron 916 alertas positivas falsas por ventana de seis horas, equivalentes a 1.29 ventanas por máquina/semana. Una ventana repetida no representa necesariamente otra orden de mantenimiento: deduplicar episodios y validar con técnicos antes de cualquier intervención.

En el piloto de doce máquinas no vistas la precisión de alerta fue 16.4% y el F1 0.228. Estos indicadores limitan la utilidad potencial aun cuando la curva ROC muestre capacidad de ranking.

5. Curvas Precision-Recall y desbalance

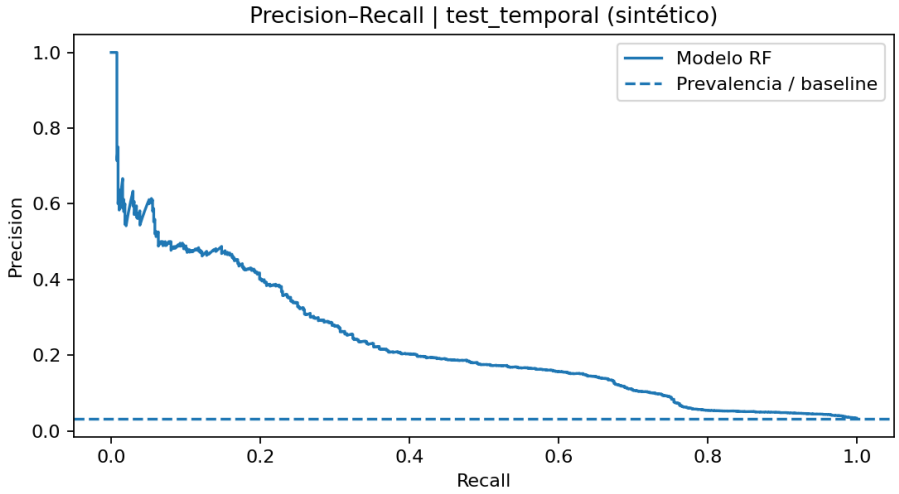


Figura 1. Curva PR de prueba temporal; la línea horizontal es prevalencia sintética.

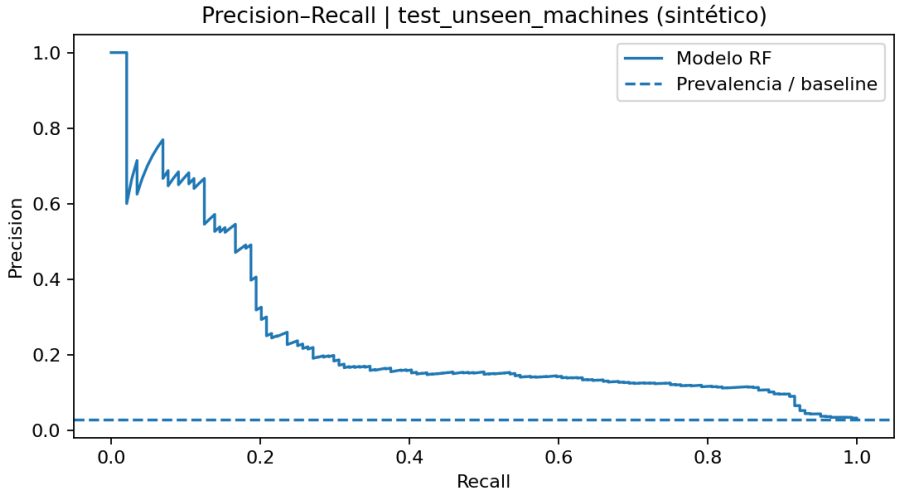


Figura 2. Curva PR del piloto de 12 máquinas no vistas. Sin inferencia industrial.

La prevalencia de fallas futuras observables fue 3.26% en test temporal y 2.89% en el piloto. AP fue 0.229 y 0.242, respectivamente. Es más informativo evaluar AP/precision-recall que apoyarse solo en exactitud ante eventos poco frecuentes.

6. Matrices de confusión

Conjunto	TN	FP	FN	TP
Temporal	18342	916	407	241
12 máquinas no vistas	4571	276	90	54

Un FP representa una alarma emitida en una ventana sin falla dentro de 72 horas. Un FN representa una ventana con falla futura que no genera alarma. La misma falla puede generar múltiples ventanas positivas consecutivas; por eso se reporta por separado la detección de eventos.

7. Pruebas funcionales reales con Docker

Caso	Verificación automatizada	Esperado
T01	Docker Compose construye API y Streamlit	2 servicios ejecutados
T02	GET /health	Modelo cargado y SQLite healthy
T03	GET /machines	Doce máquinas no vistas
T04	POST /predict PM-049	72h; registro persistido
T05	POST /predict what-if	Nueva predicción aceptada
T06	GET /predictions	Consulta auditada en SQLite
T07	Máquina ajena al piloto	HTTP 404
T08	Desgaste fuera de rango	HTTP 422
T09	Temperatura o campo inválidos	HTTP 422
T10	GET Streamlit /_stcore/health	HTTP 200

El workflow de integración se declara aprobado solo cuando los casos anteriores terminan sin error. Evidencia verificable en GitHub Actions del repositorio, no capturas simuladas.

8. Casos extremos, interpretación y deuda técnica

Se validaron límites de entrada en API mediante Pydantic: desgaste mayor a 1 y temperaturas fuera de rango reciben 422, identificadores inexistentes reciben 404 y un campo no declarado es rechazado. Los escenarios extremos dentro de rangos se aceptan para análisis hipotético; no se inventa una probabilidad fija para ellos.

9. Riesgos de validez de la solución

El generador sintético contiene una dinámica explícita de degradación que correlaciona vibración y temperatura con fallas futuras. El modelo puede aprender esa regla; su desempeño no prueba capacidad predictiva en una planta real. Las máquinas no vistas comparten la lógica generadora, por lo que la generalización externa sigue sin comprobar.

La frecuencia de evaluación es de 6 horas y el horizonte predice la presencia de alguna falla durante las 72 horas posteriores, no la hora exacta. Los umbrales BAJO/MEDIO son orientativos; la frontera ALTO corresponde al umbral seleccionado en validación.

10. Recomendaciones de evolución y MLOps

Incorporar sensores históricos reales etiquetados por evento de falla, identificación de reparaciones, ventanas de mantenimiento, revisión por ingenieros de confiabilidad, prueba prospectiva y monitoreo de drift. Separar alertas repetidas en episodios para estimar carga real de trabajo. Mantener aprobación humana.

11. Evidencias locales pendientes

La aplicación se probó en contenedores reales dentro de GitHub Actions. Para demostrar ejecución en la computadora del estudiante se requieren capturas auténticas de Docker Desktop, navegador Streamlit y Swagger. No se fabrican capturas ni se declara una prueba local aún no realizada.

12. Bibliografía y declaración de IA

Código, manifiesto SHA256 y CI: Predictive Maintenance AI Fase II. ChatGPT ayudó a construir y revisar código, pruebas y documentación; todas las métricas provienen de ejecuciones reproducibles.